

Yapay Zeka Staj Projesi: Regresyon ile Diyabet İlerleme Tahmini

Proje Amacı ve Tanımı

Bu ödevde, klinik ve demografik verileri kullanarak hastaların diyabet ilerleme skorunu (hedef değişken) tahmin eden bir regresyon modeli geliştirmeniz beklenmektedir. Gerçek dünya verilerinde sıkça karşılaşılan eksik veriler, aykırı değerler ve özellik mühendisliği (feature engineering) gibi adımları uygulayarak en düşük hata oranına sahip modeli üretmelisiniz.

1. Veri Seti Hakkında

Ödevde, scikit-learn kütüphanesinde yerleşik olarak bulunan (`sklearn.datasets.load_diabetes``) veya Kaggle üzerinden erişilebilen klasik Diabetes Dataset kullanılacaktır.

Özellikler (Features):

- **Age:** Yaş
- **Sex:** Cinsiyet
- **BMI (Body Mass Index):** Vücut kitle indeksi
- **BP (Blood Pressure):** Ortalama kan basıncı
- **s1 - s6 (Kan Serum Ölçümleri):** Toplam kolesterol, LDL, HDL, TCH, LTG, GLU gibi 6 farklı kan serumu değeri.
- **Target (Hedef Değişken):** Hastalığın başlangıcından bir yıl sonraki hastalık ilerlemesinin nicel (kantitatif) ölçümü. (Not: Bu ödev bir sınıflandırma değil, bu sürekli değeri tahmin etmeye yönelik bir regresyon ödevidir).

2. Değerlendirme Metrikleri ve Uygulama Rehberi

Modelinizin performansını ölçmek ve hataları analiz etmek için aşağıdaki regresyon metriklerini kullanmanız ve raporlamanız gerekmektedir:

- **MAE (Mean Absolute Error):** Gerçek değerler ile tahminler arasındaki mutlak farkların ortalamasıdır. Hatanın büyüklüğünü doğrudan hedef değişken birimiyle açıklar.
- **MSE (Mean Squared Error):** Hataların karesinin ortalamasıdır. Büyük hataları daha ağır cezalandırdığı için aykırı değerlerin etkisini görmede önemlidir.
- **RMSE (Root Mean Squared Error):** MSE'nin kareköküdür. Hatanın ölçeğini orijinal hedef değişken birimine geri getirir ve yorumlamayı kolaylaştırır.
- **R² Score (Açıklayıcılık Oranı):** Modelinizin verideki varyansın yüzde kaçını açıklayabildiğini gösterir. 1'e ne kadar yakınsa model o kadar başarılıdır.

Stajyerler Bu Metrikleri Nasıl Öğrenecek ve Uygulayacak?

- 1. Teorik Öğrenme:** scikit-learn resmi dokümantasyonundaki 'Regression Metrics' başlığını ve Khan Academy / Coursera üzerindeki regresyon hata analizi videolarını inceleyin.
- 2. Kod Entegrasyonu:** `sklearn.metrics` modülü altından `mean\_absolute\_error`, `mean\_squared\_error`, `root\_mean\_squared\_error` ve `r2\_score` fonksiyonlarını projenize import edin.
- 3. Model Kıyaslama Tablosu:** Eğittiğiniz Baseline (Linear Regression), Regüle (Ridge/Lasso) ve Ağaç Tabanlı (Random Forest/XGBoost) modellerin test seti sonuçlarını bu 4 metrik üzerinden karşılaştırmalı bir DataFrame/Tablo haline getirin.
- 4. Hata Analizi Görselleştirme:** Gerçek değerler (y_{test}) ile tahmin edilen değerleri (y_{pred}) serpilme grafiğinde (Scatter Plot) çizdirerek mükemmel tahmin doğrusuna ($y=x$) ne kadar yakın olduğunuzu görsel olarak yorumlayın.

Stajyer Tavsiyesi

İpucu: Sadece yüksek R^2 değerine odaklanmayın. RMSE ve MAE değerlerinin arasındaki farkı inceleyerek modelinizin büyük hatalar yapıp yapmadığını (aykırı tahminler) mutlaka değerlendirin.